


Processamento de Imagens

Aula 08: Segmentação



Prof. Linder Cândido da Silva

Agenda

- Fundamentos.
- Detecção de pontos, linhas e bordas.
- Detecção de pontos isolados.
- Detecção de linhas.
- Bordas.

Fundamentos


Introdução

- Segmentar uma imagem significa particioná-la de modo a separar os objetos de interesse do plano de fundo (background).
- A maioria dos algoritmos de segmentação que veremos baseia-se em **descontinuidades** e/ou **similaridades** nos valores de intensidade dos pixels da imagem.
- A segmentação **baseada em descontinuidade**, consiste em particionar a imagem em regiões com base em mudanças abruptas de intensidade, como bordas.
- A segmentação **baseada em similaridade** visa o particionamento da imagem em regiões semelhantes, segundo um conjunto de critérios predefinidos


Formalização

- Dado que R representa toda a região espacial ocupada por uma imagem, a segmentação pode ser vista como um processo que particiona R em n sub-regiões, $R_1, R_2, \dots, R_n$, tal que:
 - a) $\bigcup_{i=1}^n R_i = R$.
 - b) R_i é um conjunto conectado para $i = 1, 2, \dots, n$
 - c) $R_i \cap R_j = \emptyset$ para $i \neq j$.
 - d) $Q(R_i) = \text{True}$, para $i = 1, 2, \dots, n$. Onde $Q(R_i)$ é um predicado lógico definido sobre os pontos do conjunto R_i .
 - e) $Q(R_i \cup R_j) = \text{False}$, para quaisquer regiões adjacentes R_i e R_j . Diz-se que duas regiões R_i e R_j são adjacentes se a sua união forma um conjunto conectado.

Exemplo



Segmentação Baseada em
Descontinuidade



Segmentação Baseada em
Similaridade de Regiões

Detecção de Pontos, Linhas e Bordas

Pontos, Linhas e Segmentos de Borda

- Vamos começar nosso estudo focando inicialmente na segmentação de **pontos isolados, linhas e bordas**. As definições são as seguintes:
- **Pixels de borda** são pixels de uma imagem nos quais a intensidade muda abruptamente, e **segmentos de borda** são conjuntos de pixels de borda conectados.
- **Uma linha** pode ser vista como um segmento de borda (tipicamente fino), no qual a intensidade do fundo em ambos os lados da linha é muito maior ou muito menor do que a intensidade dos pixels da linha.
- Finalmente, **um ponto** isolado pode ser visto como um pixel de primeiro plano (ou de fundo) cercado por pixels de fundo (ou de primeiro plano).

Relembrando: Operações Derivativas

- Os métodos de detecção de pontos, linhas e bordas são baseados em aproximações para operações derivativas de primeira e segunda ordem.
- Aproximações para as derivadas de primeira ordem incorporam as seguintes propriedades:
 - São zero em áreas de intensidade constante.
 - São diferente de zero no início de um degrau ou rampa de intensidade.
 - São diferente de zero em pontos ao longo de uma rampa de intensidade.
- Aproximações para as derivadas de segunda ordem incorporam as seguintes propriedades:
 - São zero em áreas de intensidade constante.
 - São diferente de zero no início e no final de uma degrau ou rampa de intensidade.
 - São zero ao longo das rampas de intensidade.

Relembrando: Operações Derivativas

- Obtemos aproximações da derivada de primeira ordem expandindo a função $f(x)$ em uma série de Taylor em torno de um ponto arbitrário x .

$$\begin{aligned} f(x + \Delta x) &= f(x) + \Delta x \frac{\partial f(x)}{\partial x} + \frac{(\Delta x)^2}{2!} \frac{\partial^2 f(x)}{\partial x^2} + \frac{(\Delta x)^3}{3!} \frac{\partial^3 f(x)}{\partial x^3} + \dots \\ &= \sum_{n=0}^{\infty} \frac{(\Delta x)^n}{n!} \frac{\partial^n f(x)}{\partial x^n} \end{aligned}$$

- Para imagens $\Delta x = 1$, quando estamos olhando à frente (forward difference) ou $\Delta x = -1$, quando estamos olhando para trás (backward difference).

Relembrando: Forward Difference

- Obtemos com $\Delta x = 1$.

$$\begin{aligned} f(x+1) &= f(x) + \frac{\partial f(x)}{\partial x} + \frac{1}{2!} \frac{\partial^2 f(x)}{\partial x^2} + \frac{1}{3!} \frac{\partial^3 f(x)}{\partial x^3} + \dots \\ &= \sum_{n=0}^{\infty} \frac{1}{n!} \frac{\partial^n f(x)}{\partial x^n} \end{aligned}$$

Relembrando: Backward Difference

- Obtemos com $\Delta x = -1$.

$$\begin{aligned} f(x-1) &= f(x) - \frac{\partial f(x)}{\partial x} + \frac{1}{2!} \frac{\partial^2 f(x)}{\partial x^2} - \frac{1}{3!} \frac{\partial^3 f(x)}{\partial x^3} + \dots \\ &= \sum_{n=0}^{\infty} \frac{(-1)^n}{n!} \frac{\partial^n f(x)}{\partial x^n} \end{aligned}$$

Relembrando: Derivadas Primeiras

- Usando apenas os termos lineares, podemos aproximar as derivadas de primeira ordem de três maneiras:

(1)

$$\frac{\partial f(x)}{\partial x} = f'(x) = f(x+1) - f(x)$$

(forward difference)

(2)

$$\frac{\partial f(x)}{\partial x} = f'(x) = f(x) - f(x-1)$$

(backward difference)

(3)

$$\frac{\partial f(x)}{\partial x} = f'(x) = \frac{f(x+1) - f(x-1)}{2}$$



(central difference)

Relembrando: Derivada Segunda

- A derivada de segunda ordem é obtida adicionando as duas expansões com $\Delta x = 1$ (forward difference) e $\Delta x = -1$ (backward difference).

$$\frac{\partial^2 f(x)}{\partial x^2} = f''(x) = f(x+1) - 2f(x) + f(x-1)$$

Ilustração das Propriedades das Derivadas



Resumo

- Chegamos às seguintes conclusões:
 1. Derivadas de primeira ordem geralmente produzem bordas mais espessas.
 2. Derivadas de segunda ordem apresentam uma resposta mais intensa a detalhes finos, como linhas delgadas, pontos isolados e ruído.
 3. Derivadas de segunda ordem produzem uma resposta de borda dupla em transições de intensidade do tipo rampa e degrau.
 4. O sinal da derivada de segunda ordem pode ser utilizado para determinar se a transição que forma uma borda ocorre de claro para escuro ou de escuro para claro.

Relembrando: Como as Derivadas São Calculadas

- A abordagem preferida para calcular as derivadas de primeira e segunda ordem em cada localização de pixel de uma imagem é usar convolução espacial.

$$\begin{aligned} Z &= w_1 z_1 + w_2 z_2 + \dots + w_9 z_9 \\ &= \sum_{k=1}^9 w_k z_k \end{aligned}$$

w_1	w_2	w_3
w_4	w_5	w_6
w_7	w_8	w_9

- Onde z_k é a intensidade do pixel cuja localização espacial corresponde à localização do k-ésimo coeficiente do kernel.

Detecção de Pontos Isolados

Detecção de Pontos Isolados

- Devido a maior sensibilidade, a detecção de pontos isolados é normalmente baseada na derivada de segunda ordem. Isso significa usar o Laplaciano:

$$\nabla^2 f(x, y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

$$\nabla^2 f(x, y) = f(x+1, y) + f(x-1, y) + f(x, y+1) + f(x, y-1) - 4f(x, y)$$

0	1	0
1	-4	1
0	1	0

Detecção de Pontos Isolados

- Um ponto é detectado em (x, y) se ao centrarmos o kernel laplaciano nessa coordenadas obtivermos um resposta que exceda um limiar T especificado.
- Na imagem de saída $g(x, y)$ esses pontos são rotulados como 1 e todos os outros são rotulados como 0, produzindo assim uma imagem binária.

$$g(x, y) = \begin{cases} 1 & \text{if } |Z(x, y)| > T \\ 0 & \text{otherwise} \end{cases}$$




Exemplo

a

b c d

1	1	1
1	-8	1
1	1	1

- a) *Kernel Laplaciano utilizado para detecção de pontos.*
- b) *Imagem de raios X de uma pá de turbina com porosidade manifestada por um único pixel preto.*
- c) *Resultado da convolução do kernel com a imagem.*
- d) *Limiarização com T igual a 90% do maior valor absoluto de pixel da imagem (c).*




Detecção de Linhas

Detecção de Linhas

- Para detectar linhas, as segundas derivadas também resultam em uma resposta de filtro mais forte e produzem linhas mais finas do que as primeiras derivadas.
- Assim, também podemos usar o kernel Laplaciano para detecção de linha, tendo em mente que o efeito de linha dupla da segunda derivada deve ser tratado adequadamente. Em geral, é apropriado usar apenas os valores positivos da laplaciana.
- Quando falamos sobre detecção de linha, supõe-se que as linhas sejam finas em relação ao tamanho do detector. Linhas que não satisfazem esta suposição são consideradas regiões e tratadas pelos métodos de detecção de bordas.

Exemplo



a	b
c	d


- a. Imagem original.
- b. Imagem laplaciana; o ampliado mostra o efeito de linha dupla positivo/negativo característico do Laplaciano.
- c. Valor absoluto do Laplaciano.
- d. Valores positivos do Laplaciano.

Detecção de Linhas

- O kernel Laplaciano é isotrópico, portanto sua resposta é independente da direção (vertical, horizontal e duas diagonais).
- Mas, muitas vezes o interesse reside na detecção de linhas em direções específicas. Para esses casos, usamos kernels tais como os apresentados abaixo, os quais produzem respostas mais fortes para linhas de um pixel em direções específicas.

-1	-1	-1	2	-1	-1	-1	2	-1	-1	-1	2
2	2	2	-1	2	-1	-1	2	-1	-1	2	-1
-1	-1	-1	-1	-1	2	-1	2	-1	2	-1	-1
Horizontal			+45°			Vertical			-45°		

Exemplo




- (a) Imagem original. (b) Resultado do processamento com o kernel detector de linha $+45^\circ$. (c) Vista ampliada da região superior esquerda de (b). (d) Vista ampliada da região inferior direita de (b). (e) A imagem em (b) com todos os valores negativos definidos como zero. (f) Todos os pontos (em branco) cujos valores satisfizeram a condição $g > T$, onde g é a imagem em (e) e $T = 254$ (o valor máximo de pixel na imagem menos 1). (Os pontos em (f) foram ampliados para facilitar a visualização.)

Detecção de Bordas

O Que Constitui Uma Borda?

- Bordas consistem em transições relativamente bruscas no perfil de intensidade de uma imagem.
- Bordas desempenham um papel muito importante na visão humana e provavelmente também em muitos outros sistemas de visão biológica.
- Muitas vezes é possível descrever ou reconstruir uma figura completa a partir de algumas bordas.
- A figura ao lado mostra um avião com foco na turbina. E, abaixo, algumas bordas da imagem.



Modelos de Bordas

- Os modelos bordas são classificados de acordo com seus perfis de intensidade associados à formação da borda.
- Estabelecer modelos nos permitem escrever expressões matemáticas para bordas no desenvolvimento de algoritmos de processamento de imagens.
- O desempenho desses algoritmos dependerá das diferenças entre as bordas reais e os modelos utilizados no desenvolvimento dos algoritmos.


Modelos de Bordas: Step-Edge

- Uma borda em degrau (step-edge) é um modelo bastante idealizado caracterizado por uma transição entre dois níveis de intensidade que ocorre idealmente na distância de um pixel.




Modelos de Bordas: Ramp-Edge

- Em geral as imagens digitais têm bordas desfocadas e ruidosas. Nessas situações, as bordas são melhor modeladas como um perfil caracterizado por uma rampa de intensidade.




Modelos de Bordas: Ramp-Edge

- Um borda com perfil em rampa pode ser detectada como uma borda espessa por filtros baseados na derivada primeira. A derivada segunda detecta os extremos da borda, tal como indicado abaixo.




Modelos de Bordas: Roof-Edge

- Os modelos de bordas com perfil de “telhado” são caracterizados por linhas que atravessam uma região. A largura da borda é determinada pela espessura e nitidez da linha. No limite, quando ela tem um pixel de largura, a borda telhada nada mais é do que uma linha com um pixel de espessura que atravessa uma região de uma imagem.




Perfis de Borda em Imagens Reais



Sensibilidade dos Operadores Derivativos ao Ruído

- A primeira coluna mostra uma imagem com uma borda em rampa. Na primeira linha a imagem não apresenta ruídos, mas nas linhas subsequentes são adicionados ruídos gaussianos com média 0 e desvio padrão 0.1, 1 e 10 unidades de intensidade.
- A segunda coluna apresenta o perfil da derivada primeira.
- A terceira coluna apresenta o perfil da derivada segunda.



Metodologia Geral para Detecção de Bordas

- As três etapas normalmente executadas para detecção de bordas são as seguintes:
 1. Suavização da imagem para redução de ruído. A necessidade desta etapa deve-se a forte influência que os ruídos exercem nos operadores derivativos.
 2. Detecção de pontos de borda. Esta é uma operação local que extrai de uma imagem todos os pontos que são potenciais candidatos a pontos de borda. Pode ser realizada com a derivada primeira e/ou com a derivada segunda.
 3. Localização de borda. O objetivo desta etapa é selecionar dos pontos candidatos apenas aqueles que são realmente membros do conjunto de pontos que compõem um segmento de borda.

Detecção de Bordas Baseado em Gradiente


- O gradiente é o vetor cujas componentes são as derivadas parciais de primeira ordem.

$$\nabla f \equiv \text{grad}(f) = \begin{bmatrix} g_x \\ g_y \end{bmatrix} = \begin{bmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{bmatrix}$$

- Sua principal propriedade é que ele aponta para a direção de maior aumento de intensidade da função.

Detecção de Bordas Baseado em Gradiente

- O vetor gradiente aponta para a direção de maior variação da função.



- Se essa superfície for interpretada como uma imagem, teríamos o centro escuro clareando para as laterais.
- No plano estão indicados a direção do vetor gradiente.

Detecção de Bordas Baseado em Gradiente

- Existem várias formas de especificar de forma aproximada o valor das derivadas parciais de primeira ordem.
- Ao lado, apresentamos as aproximações mais comumente empregadas.

-1	0	0	-1
0	1	1	0

Roberts

-1	-1	-1	-1	0	1
0	0	0	-1	0	1
1	1	1	-1	0	1


Prewitt

-1	-2	-1	-1	0	1
0	0	0	-2	0	2
1	2	1	-1	0	1

Sobel

Detecção de Bordas Baseado em Gradiente


- A partir do gradiente calculamos a magnitude e a orientação local. Os pixels candidatos a borda são selecionados por Limiarização.



Detecção de Bordas Baseado em Gradiente

- A borda é sempre perpendicular ao vetor gradiente.

$$\alpha(x, y) = \tan^{-1} \left[\frac{g_y(x, y)}{g_x(x, y)} \right]$$



Magnitude do Gradiente



Imagens originais

(a)



Componentes
estimadas usando os
filtros de Sobel

(b)



Kernels de Compasso de Kirsch

- Os filtros de Prewitt e Sobel exibem resposta mais forte para bordas verticais e horizontais.
- Os kernels de Kirsch detectam magnitude e direção em todas as oito direções principais.
- Em cada ponto verifica-se o filtro com maior resposta. O valor calculado determina a magnitude do gradiente, o ângulo da borda (indicado abaixo do kernel) é diretamente determinado pelo filtro vencedor.

<table><tr><td>-3</td><td>-3</td><td>5</td></tr><tr><td>-3</td><td>0</td><td>5</td></tr><tr><td>-3</td><td>-3</td><td>5</td></tr></table>	-3	-3	5	-3	0	5	-3	-3	5	<table><tr><td>-3</td><td>5</td><td>5</td></tr><tr><td>-3</td><td>0</td><td>5</td></tr><tr><td>-3</td><td>-3</td><td>-3</td></tr></table>	-3	5	5	-3	0	5	-3	-3	-3	<table><tr><td>5</td><td>5</td><td>5</td></tr><tr><td>-3</td><td>0</td><td>-3</td></tr><tr><td>-3</td><td>-3</td><td>-3</td></tr></table>	5	5	5	-3	0	-3	-3	-3	-3	<table><tr><td>5</td><td>5</td><td>-3</td></tr><tr><td>5</td><td>0</td><td>-3</td></tr><tr><td>-3</td><td>-3</td><td>-3</td></tr></table>	5	5	-3	5	0	-3	-3	-3	-3
-3	-3	5																																					
-3	0	5																																					
-3	-3	5																																					
-3	5	5																																					
-3	0	5																																					
-3	-3	-3																																					
5	5	5																																					
-3	0	-3																																					
-3	-3	-3																																					
5	5	-3																																					
5	0	-3																																					
-3	-3	-3																																					
N	NW	W	SW																																				
<table><tr><td>5</td><td>-3</td><td>-3</td></tr><tr><td>5</td><td>0</td><td>-3</td></tr><tr><td>5</td><td>-3</td><td>-3</td></tr></table>	5	-3	-3	5	0	-3	5	-3	-3	<table><tr><td>-3</td><td>-3</td><td>-3</td></tr><tr><td>5</td><td>0</td><td>-3</td></tr><tr><td>5</td><td>5</td><td>-3</td></tr></table>	-3	-3	-3	5	0	-3	5	5	-3	<table><tr><td>-3</td><td>-3</td><td>-3</td></tr><tr><td>-3</td><td>0</td><td>-3</td></tr><tr><td>5</td><td>5</td><td>5</td></tr></table>	-3	-3	-3	-3	0	-3	5	5	5	<table><tr><td>-3</td><td>-3</td><td>-3</td></tr><tr><td>-3</td><td>0</td><td>5</td></tr><tr><td>-3</td><td>5</td><td>5</td></tr></table>	-3	-3	-3	-3	0	5	-3	5	5
5	-3	-3																																					
5	0	-3																																					
5	-3	-3																																					
-3	-3	-3																																					
5	0	-3																																					
5	5	-3																																					
-3	-3	-3																																					
-3	0	-3																																					
5	5	5																																					
-3	-3	-3																																					
-3	0	5																																					
-3	5	5																																					
S	SE	E	NE																																				

Bordas em Diferentes Escalas

- Infelizmente, a detecção de bordas simples que discutimos até agora muitas vezes não detectam aquilo que nós, humanos, percebemos como bordas importantes. As duas principais razões são:
 - Os operadores respondem apenas a diferenças de intensidade locais, enquanto nosso sistema visual é capaz de estender as bordas por áreas de contraste mínimo.
 - As bordas não existem com resolução e escala fixas, mas em toda uma gama de escalas diferentes.
- Exemplo, o operador Sobel só responde a diferenças de intensidade dentro da região 3×3 do filtro. Para detectar bordas em uma escala maior, precisaríamos de filtros grandes ou usar os filtros originais em imagens reescaladas.
- As técnicas de “multirresolução” detectam as bordas em vários níveis de escala e depois decidem qual borda (se houver) em qual nível de escala é dominante em cada posição na imagem.

Detector de Bordas de Canny

- Um método multiresolução popular para detecção de bordas é o método de Canny, desenvolvido por John F. Canny em 1986.
- Este método emprega um conjunto de filtros orientados relativamente grandes em múltiplas resoluções de imagem e mescla os resultados individuais em um mapa de borda comum. Frequentemente, entretanto, apenas a implementação de escala única do algoritmo com um raio de filtro ajustável (parâmetro de suavização σ) é usada, o que, ainda assim, é superior à maioria dos operadores de detecção de bordas simples que vimos até o momento.
- O método tenta atingir três objetivos principais: (1) minimizar o número de pontos falsos nas bordas, (2) conseguir uma boa localização das bordas e (3) entregar uma única marca em cada borda. Em sua essência, o algoritmo de Canny é um método baseado em gradiente, mas usa os cruzamentos das derivadas segundas (zero crossing) para uma localização precisa das bordas.

Detector de Bordas de Canny

- Dado que $f(x, y)$ denota a imagem de entrada e $G(x, y)$ denota a função gaussiana:

$$G(x, y) = e^{-\frac{x^2 + y^2}{2\sigma^2}}$$

- O primeiro passo implementado pelo detector de bordas de Canny é obter a imagem suavizada $f_s(x, y)$ fazendo a convolução de f e g :

$$f_s(x, y) = G(x, y) \star f(x, y)$$

Detector de Bordas de Canny (Cont.)

- O segundo passo consiste em calcular a magnitude e orientação do gradiente em todos os pontos da imagem:

$$M_s(x, y) = \|\nabla f_s(x, y)\| = \sqrt{g_x^2(x, y) + g_y^2(x, y)}$$

$$\alpha(x, y) = \tan^{-1} \left[\frac{g_y(x, y)}{g_x(x, y)} \right]$$

- Tenha em mente que a magnitude e a orientação dos gradientes, $\|\nabla f_s(x, y)\|$ e $\alpha(x, y)$, são arrays do mesmo tamanho da imagem a partir da qual são calculados.

Detector de Bordas de Canny (Cont.)

- A imagem de gradientes, $\|\nabla f_s(x, y)\|$, normalmente contém “cristas” largas em torno dos máximos locais que definem a posição das bordas. O próximo passo é afinar essas cristas.
- Uma abordagem consiste em usar supressão de não máximos e calcular uma nova imagem $g_N(x, y)$ a partir da imagem de gradientes. A essência do processo consiste em especificar uma série de orientações discretas para as normais da borda (vetor gradiente). Por exemplo, em uma região 3×3 podemos definir quatro orientações para a borda que passa pelo ponto central da região: horizontal, vertical, $+45^\circ$ e -45° .
- O slide a seguir ilustra a quantização das direções de acordo com intervalos de associação dos gradientes.




Detector de bordas de Canny (Cont.)

a b
c

(a) Duas orientações possíveis de uma borda horizontal em uma vizinhança 3×3 .

(b) Faixa de valores (sombreado) do ângulo de direção da normal a uma borda horizontal (α).

(c) Os intervalos de ângulos das normais às arestas para os quatro tipos de direções em uma vizinhança 3×3 . Cada direção da borda possui dois intervalos, mostrados em tons correspondentes.



Detector de Bordas de Canny (Cont.)

- Definindo d_1, d_2, d_3 e d_4 como as quatro direções básicas, podemos formular o seguinte esquema de supressão de não máximos para uma região 3×3 centrada em um ponto arbitrário (x, y) de α :
 - Encontre a direção d_k que está mais próxima de $\alpha(x, y)$.
 - Se o valor de $\|\nabla f_s(x, y)\|$ em (x, y) for menor que o valor em um ou ambos os vizinhos do ponto (x, y) ao longo da direção d_k , então faça $g_N(x, y) = 0$ (supressão); caso contrário, seja $g_N(x, y) = f_s(x, y)$.
- Quando repetido para todos os pontos (x, y) , este procedimento produz a imagem $g_N(x, y)$ do mesmo tamanho da imagem de gradientes com os não máximos suprimidos.

Detector de Bordas de Canny (Cont.)

- A operação final consiste em histerese, ou seja Limiarizar $g_N(x, y)$ para reduzir as bordas.
- São usados dois limiares: um limiar baixo, T_L , e um limiar alto, T_H . Evidências experimentais sugerem que a proporção entre T_H e T_L deve estar na faixa de 2:1 a 3:1. Calculamos:

$$g_{NH}(x, y) = g_N(x, y) \geq T_H$$

$$g_{NL}(x, y) = g_N(x, y) \geq T_L$$

- Em seguida:
- $$g_{NL}(x, y) = g_{NL}(x, y) - g_{NH}(x, y)$$

Detector de Bordas de Canny (Cont.)

- Os pixels diferentes de zero em $g_{NH}(x, y)$ e $g_{NL}(x, y)$ podem ser vistos como pixels de borda “fortes” e “fracos”, respectivamente.
- Após as operações de limiarização, todos os pixels em $g_{NH}(x, y)$ são considerados pixels de borda válidos e são marcados imediatamente.
- Dependendo do valor de T_H , as bordas em $g_{NH}(x, y)$ podem apresentar lacunas. Bordas mais longas são formadas usando o seguinte procedimento:
 - Localize o próximo pixel de borda não visitado, p , em $g_{NH}(x, y)$.
 - Marque como pixels de borda válidos todos os pixels fracos em $g_{NL}(x, y)$ que estão conectados a p usando, digamos, conectividade 8.
 - Se todos os pixels diferentes de zero em $g_{NH}(x, y)$ foram visitados, vá para a Etapa 4. Caso contrário, retorne para a etapa 1.
 - Defina como zero todos os pixels em $g_{NL}(x, y)$ que não foram marcados como pixels de borda válidos.

Detector de bordas de Canny: comparação

a	b
c	d

- (a) Imagem de TC de crânio de tamanho 512×512 pixels, com valores de intensidade dimensionados para o intervalo $[0, 1]$.
- (b) Limiarização do gradiente da imagem suavizada.
- (c) Imagem obtida pelo algoritmo de Marr-Hildreth (Laplaciana da imagem suavizada com uma Gaussiana).
- (d) Imagem obtida pelo algoritmo Canny.

